Reverse engineering: une introduction

Antoxyde

Securimag

Octobre 2020



Définition théorique vague et incompréhensible

"Déconstruire" quelque chose, pour comprendre comment la chose est implémentée, comme est-ce qu'elle fonctionne, qu'est ce qu'elle fait.

Point vocabulaire

"détricoter" en français (source: bitoduc.fr), donc on va rester en anglais.



Ce qui nous intéresse

Principalement, partir d'un programme dont on n'a pas les sources, et appliquer la définition.



Buts

- Analyse de malware
- Crack de logiciel (création d'un keygen par ex.)
- Recherche de vulnérabilité
- Réimplementer du code perdu, faire de l'interopératibilité
- Pour les jeux vidéo: création de cheat, de bots, etc
- ou bien simplement satisfaire sa curiosité :-)



Exemple: Analyse de malware

Malware

2017: Marcus Hutchins (@MalwareTech) et WannaCry.





Exemple: Analyse de malware

- Le malware utilisait une Oday sur SMB (EternalBlue, leak de la NSA) qui lui permettait de se propager sur les PC non patchés sur le même réseau local
- Nom de domaine "anti-sandbox": www.iuqerfsodp9ifjaposdfjhgosurijfaewrwergwea.com



Exemple: "recréation" d'un logiciel closed source/dont on a perdu le code source

- Driver nvidia sous licence propriétaire et closed-source
- Le driver "nouveau" est développé en reversant le driver propriétaire



Point de départ

On a seulement du "code machine" (ie un amas d'octets), et on veut comprendre ce que l'ordinateur va faire en l'exécutant On peut avoir:

- Du Bytecode .pyc, .class, .luac, .mrb,
- Du "vrai" code machine: un binaire (ELF, PE, Mach-O)



Bytecode

Bytecode: exécuté sur une machine virtuelle, un interpreter.

```
2 θ LOAD_GLOBAL θ (print)
2 LOAD_CONST 1 ('Hello, World!')
4 CALL_FUNCTION 1
```

En général, on arrive à remonter à la source (uncompyle6 pour Python par exemple)



Code machine

Contient du code directement executé par le CPU.

Type d'exécutable

ELF (Linux), PE (Windows, les .exe), Mach-O (MacOS)

L'architecture

Le "type" du CPU: Intel, ARM, MIPS, .. et 32/64 bits.

Si l'archi du binaire ne correspond pas à celle de votre PC : VM/émulation (VirtualBox, Qemu, ..) ou un raspi qui traine si c'est de l'ARM.



Flags de compilation

- Dynamique (link avec les librairies au runtime) vs statique (embarque les librairies)
- Strippé : les symboles (noms de fonctions par ex.) sont retirés

Statique et strippé : tu pleures et tu reverse printf pendant 3h sans t'en rendre compte.



Techniques générales

Analyse statique

- Désassembleur : affiche le code assembleur, tout beau tout propre (ex: Radare2, Binary ninja, Cutter, IDA, Ghidra, ..)
- Décompilateur: affiche du C/C++ pas toujours très lisible.



Exemple désassemblage (Binary-Ninja)

```
main:
00001239
         push rbp {__saved_rbp}
0000123a
                 rbp, rsp {__saved_rbp}
         mov
0000123d sub
                 rsp, 0x50
                 rax, qword [fs:0x28]
00001241 mov
0000124a mov
                 qword [rbp-0x8 {var_10}], rax
0000124e xor
                 eax, eax {0x0}
00001250 lea
                 rdi, [rel data_2008] {"Whats the password ?"}
00001257 call
                 puts
0000125c lea
                 rax, [rbp-0x40 {var_48}]
00001260 mov
                 rsi, rax {var_48}
00001263 lea
                 rdi, [rel data_201d] {"%49s"}
0000126a mov
                 eax, 0x0
0000126f call
                 __isoc99_scanf
00001274 lea
                 rax, [rbp-0x40 {var_48}]
00001278 mov
                 rdi, rax {var_48}
0000127b call
                 strlen
```

Exemple décompilation (Binary-Ninja)

```
main:
    0 @ 00001241    void* fsbase
    1 @ 00001241    int64_t rax = *(fsbase + 0x28)
    2 @ 00001257    puts(str: "Whats the password ?")
    3 @ 0000126f    void var_48
    4 @ 0000126f    __isoc99_scanf(format: "%49s", &var_48)
    5 @ 00001294    if (verify_password(&var_48, zx.q(strlen(&var_48):0.d)):0.d == 0)
```



Techniques générales

Analyse dynamique

- Débuggage: gdb, IDA, x64dbg (windows),...
- Emulation, Instrumentation (Frida, ..), Hooking (LD_PRELOAD, ..), execution symbolique (Angr, miasm)..



Show time!



CTF Reversing BINGO!!!!

	"more layers means more difficulty!"	MD-5, SHA-1 or CRC	All challenges are Linux	Self- unpacking binary	RC4 or other shitty cipher
	Solution requires recognizing crypto impl	Flag checker	Custom virtual machine	Statically- linked, stripped binary	Intended solution involves guessing or side-channel
	Involves some kind of graph traversal	Unintended pintool solution	FREE Waste of time	C++ STL hell	Solution requires brute- forcing
	Shitty custom or ancient	Binary has ABI unsup- ported by	rwx segments, code caves, self-decrypting	Binary uses a COTS packer (e.g.	Crackme/



17/22

Site de challs de reverse

- La catégorie "reverse" de root-me.org (débutant/confirmé)
- crackmes.one: banque de crackmes (3246 à l'heure actuelle)
- Challenge du Flareon : 2020.flare-on.com (challenge annuel, niveau hard)
- ctf.securimag.org :sunglasses:



Vague de chall sur la plateforme (ctf.securimag.org)

4 nouveaux challenges cette semaine

- PE Switch 100 pts (PE, x86_x64)
- alARM 150 pts (ELF, ARM 32bits)
- Oh My Lib 400 pts (ELF, x86_64)
- Aïe, ca pyc! 400 pts (ELF/Bytecode python)

Et toujours Memtrap (300pts) et Cequetudisnaaucunsens (100pts)



Toolz en vrac

- Unix: file, Itrace, strace, strings (oui oui)
- Windows: Flare VM , cf github.com/fireeye/flare-vm#installed-tools pour une liste de tools
- Android/Java: apktool, dex2jar, JAD, frida,...
- Dotnet: DNSpy, DotPeek,...
- Python: uncompyle, pyinstaller,...





Sujets à creuser pour aller plus loin

en vrac aussi

- Unpacking (UPX, ..)
- Execution symbolique (angr, miasm, ..)
- Taint analysis
- Techniques d'anti-debug (Ptrace, signal trap, nanomites, ..)
- Technique d'obfuscation (VMprotect, movfuscator)
- Les tools de quarkslab



BIERE

BIERE

BIERE

